


Elasticsearch from zero to hero

An abstract graphic of a tree where the trunk and branches are composed of glowing blue lines and dots, resembling a network or data structure. The background is a deep blue with some bokeh light effects.

Gérôme Egron @GeromeEgron
Ivan Beauvais @ibeauvais

Présentation des speakers





#BeXebian
recrutement@xebia.fr

BE A BETTER **DEVELOPER**



Diffusez vos cartes dans la communauté
et devenez un ninja du développement.

Glossaire

- . Document
- . Index
- . Indexation
- . Mapping

Différents types de recherche

1. Recherche Full Text
2. Recherche Exacte
3. Aggregation



1

Recherche Full text

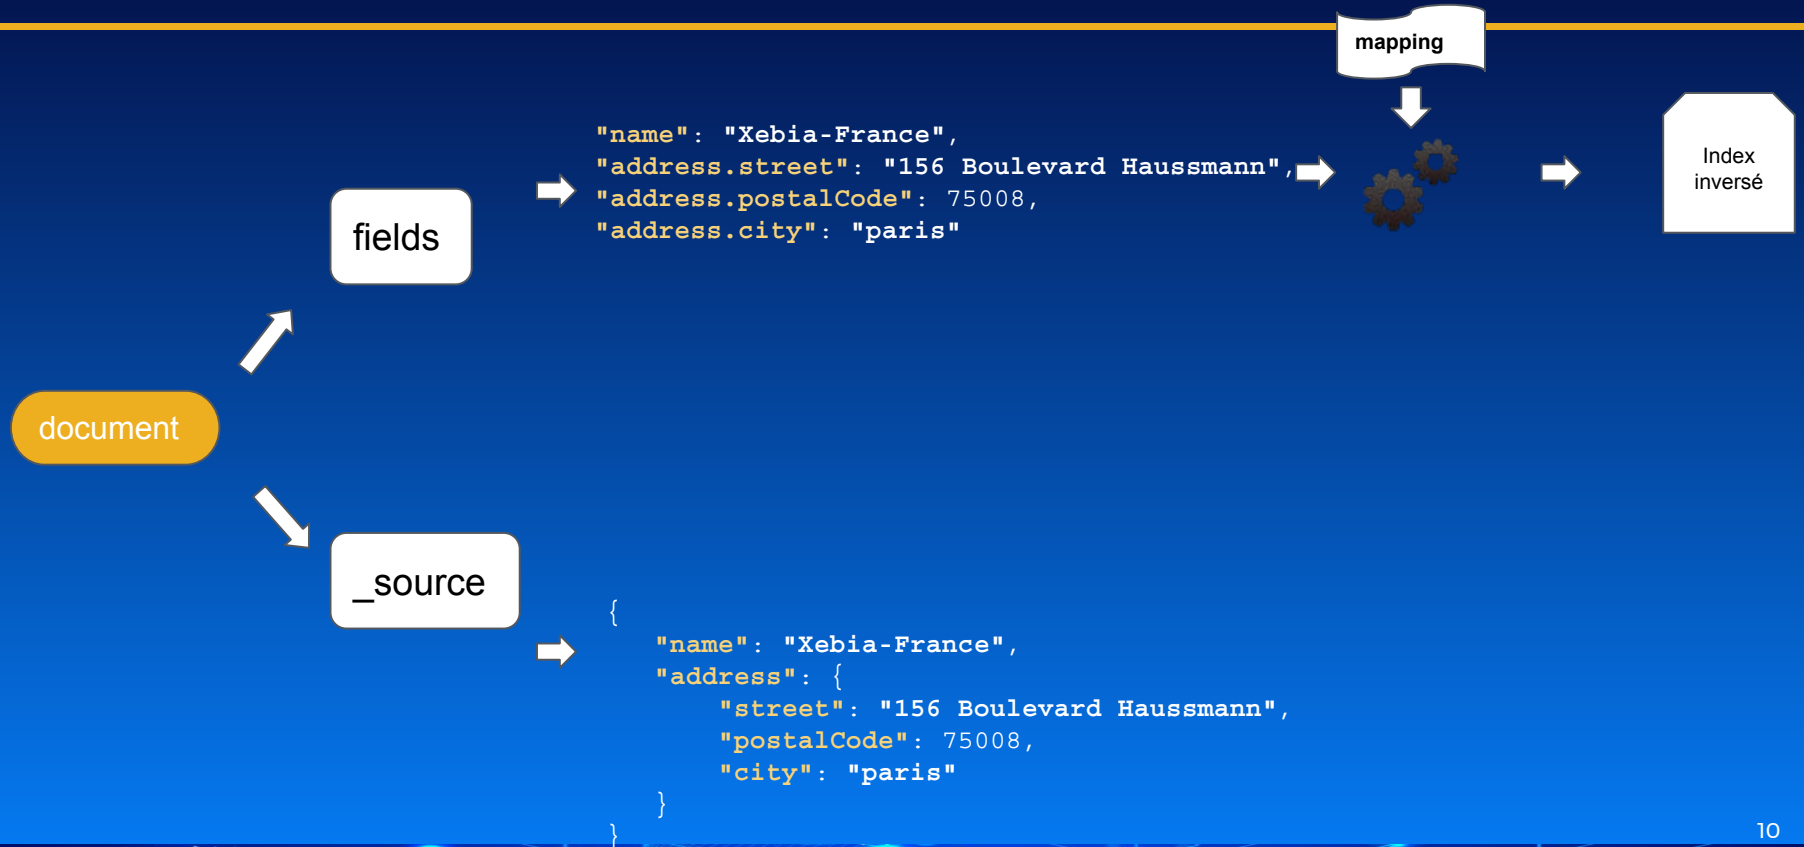
Indexation d'un document

```
POST http://localhost:9200/directory/address
{
  "name": "Xebia-France",
  "address": {
    "street": "156 Boulevard Haussmann",
    "postalCode": 75008,
    "city": "paris"
  }
}
```


Mapping correspondent

```
"name": {  
  "type": "text",  
  "fields": {  
    "keyword": {  
      "type": "keyword",  
      "ignore_above": 256  
    }  
  },  
},  
"address": {  
  "properties": {  
    "postalCode": {  
      "type": "long"  
    },  
    "street": {  
      "type": "text",  
  
      [...]
```

Traitement d'un document



Index inversé

"name": "Xebia-France"

"name": "Voyages-sncf"

"name": "sncf"



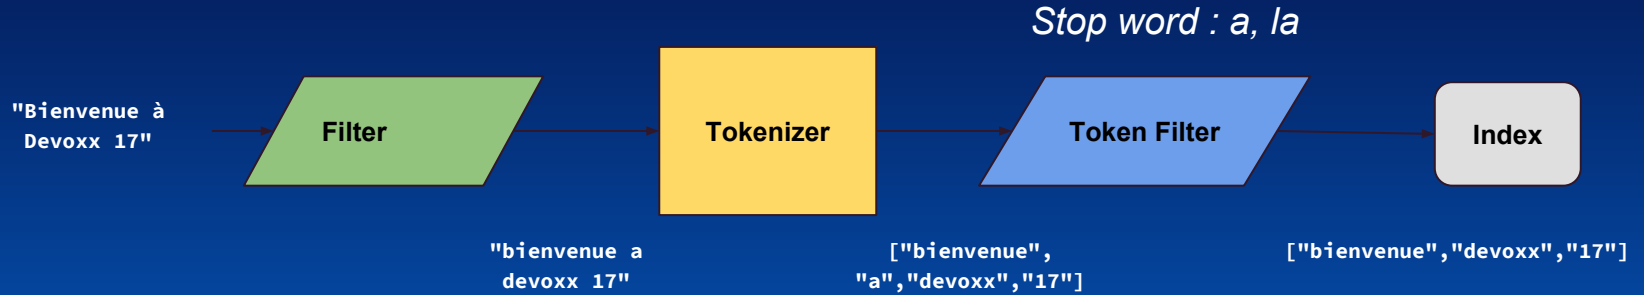
Term	Frequency	ID Document
xebia	1	1
france	1	1
voyages	1	2
sncf	2	2,3

Analyse

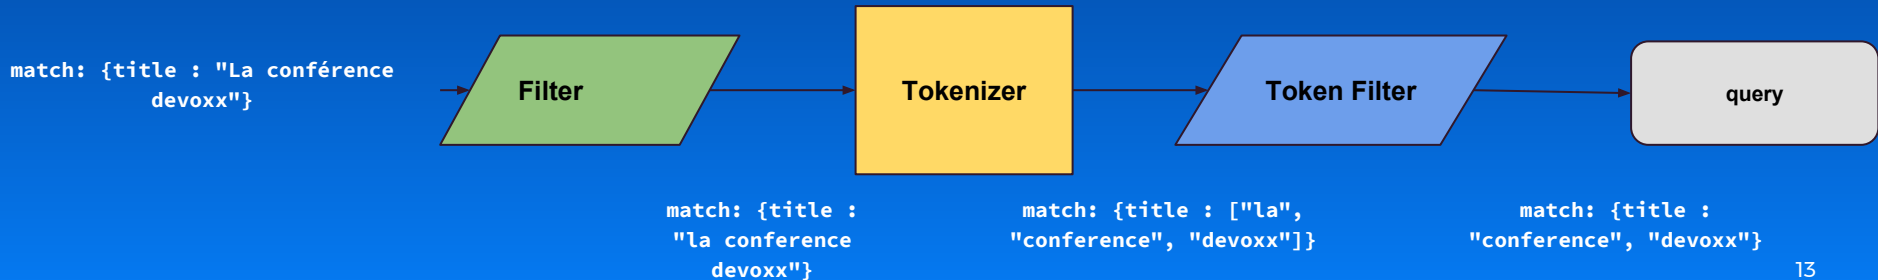
- Dépend du mapping du champ
- Effectuée en 3 phases : Filter, Tokenizer, Token Filter
- Appliquée sur les valeurs des champs avant l'enregistrement dans l'index inversé
- N'impacte pas le document original sauvegardé (_source)

Analyse : exemple

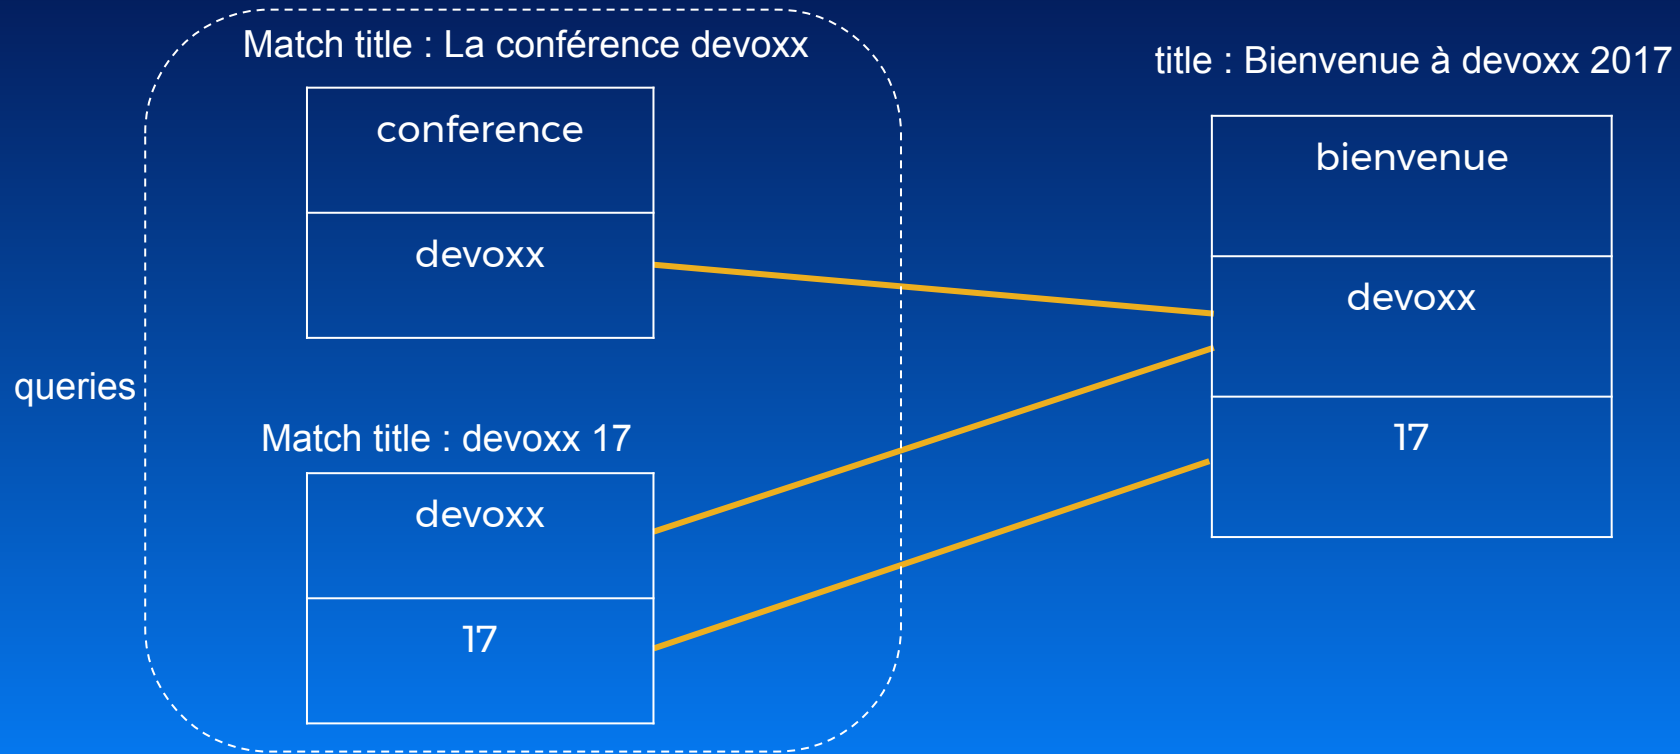
Indexation



Recherche



Le matching



Scoring des documents (BM25)

- **Term frequency** : plus un terme est présent dans un champ plus le score est élevé
- **Inverse document frequency** : plus un terme est présent dans tous les documents de l'index moins le score est élevé
- **Field-length norm** : Plus le champ est court plus le score est élevé

Match query

```
GET my_index/company/_search
{
  "query": {
    "match": {
      "name": "La conférence devoxx"
    }
  }
}
```

```
Result :
{
  "_index": "my_index",
  "_type": "company",
  "_id": "1",
  "_score": 0.2169777,
  "_source": {
    "name": "Bienvenue à Devoxx 17"
  }
}
```



2

Recherche Exacte

Recherche exacte

- Similaire à une clause "where" en SQL
- Pas de score sur les documents : le document respecte la condition ou ne la respecte pas
- Coupler à la recherche full texte permet de réduire le nombre de document à scorer
- Mis en cache

Mapping

```
"content": {  
  "type": "text",  
  "analyzer": "standard"  
}
```

Recherche Full Text


```
"author": {  
  "type": "keyword"  
}
```

```
"age": {  
  "type": "integer"  
}
```


Recherche exacte

```
"sendDate": {  
  "type": "date",  
  "format": "YYYYMMddHHmmss"  
}
```

Recherche full text vs Recherche exacte



Recherche Full Text



Recherche exacte

Bool query : must

```
GET _search
{
  "query": {
    "bool": {
      "must": [
        {
          "match": {
            "content": {
              "value": "Devoxx 2017"
            }
          }
        },
        {
          "match": {
            "content": "Elasticsearch"
          }
        }
      ]
    }
  }
}
```

Bool query : should

```
GET _search
{
  "query": {
    "bool": {
      "should": [
        {
          "match": {
            "content": {
              "value": "Devoxx 17"
            }
          }
        },
        {
          "match": {
            "content": "Breizhcamp"
          }
        }
      ]
    }
  }
}
```

Bool query : must_not

```
GET _search
{
  "query": {
    "bool": {
      "must_not": [
        {
          "match": {
            "content": {
              "value": "2015"
            }
          }
        }
      ]
    }
  }
}
```


Bool query : filter

```
GET _search
{
  "query": {
    "bool": {
      "filter": [
        {
          "term": {
            "age": {
              "value": 12
            }
          }
        }
      ]
    }
  }
}
```




3

Aggregation


Aggregation

- Equivalent à "count", "groupBy", "Max" ... en SQL
- On ne remonte plus des documents mais on collecte des informations contenues dans les champs des documents
- Utilisés conjointement aux filtres

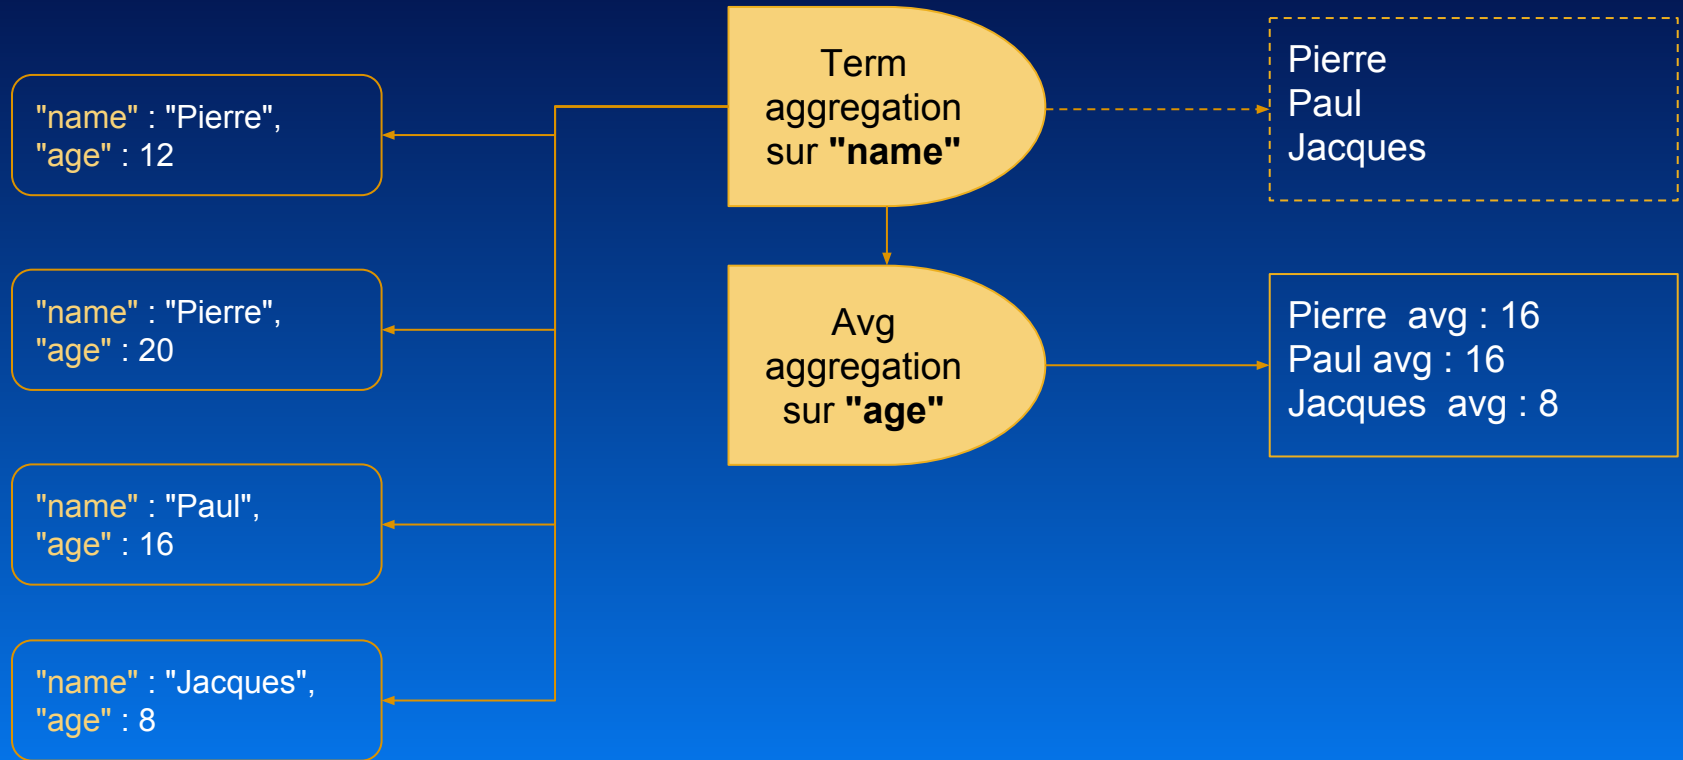
Metrics aggregation



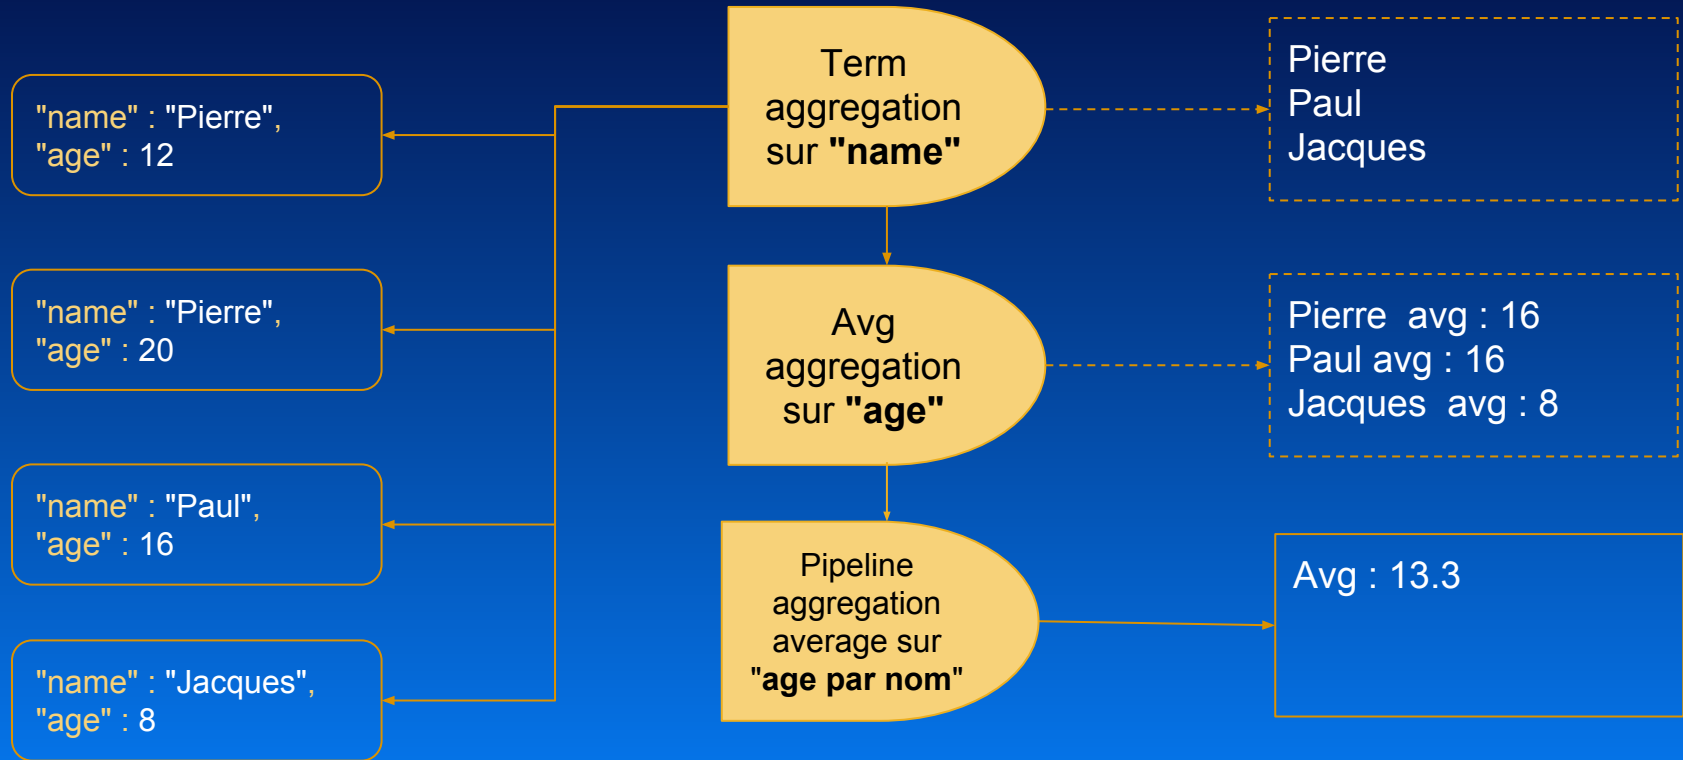
Bucket aggregation



Sub aggregation



Pipeline aggregation



Aggregation en pratique

- Moyenne, minimum, maximum des prix sur un scope de document
- Somme des valeurs d'un champ numérique de tous les documents
- Percentiles des temps de réponse stockés dans l'index
- Toutes les valeurs possibles pour un champ
- Nombre de document compris entre des plages de dates ou des coordonnées GPS



Hand's on !

<https://xebia-france.github.io/es-from-zero-to-hero/>

Vous avez vu

- Ajouter/Supprimer/Rechercher des documents
- Utiliser le mapping afin de supprimer le code html du texte
- Utiliser le mapping pour ajouter des synonymes
- Rechercher avec une "Match" query
- Filtrer sur un intervalle de date
- Faire une recherche sur plusieurs champs
- Faire de la suggestion en mode "fuzzy"
- Agréger par term et par term de term
- Faire des requêtes géolocalisées
- Faire des agrégations sur des distances à un point
- Utiliser l'agrégation de type date_histogram
- Filtrer les résultats d'une agrégation grâce à une pipeline agrégation